

Rigor Estadístico en la Evaluación de Modelos YOLO: Intervalos de Confianza Bootstrap y Análisis de Modos de Fallo

William Steve Rodriguez Villamizar

AI Leader & Solutions Architect

wisrovi-suit

Badajoz, España

wisrovi.rodriguez@gmail.com

Resumen—La dependencia de estimaciones métricas de un solo punto (por ejemplo, una puntuación solitaria de mAP) para comparar modelos de detección de objetos a menudo enmascara las varianzas estadísticas subyacentes, lo que lleva a decisiones de despliegue con exceso de confianza. Este documento propone un pipeline de validación post-entrenamiento automatizado y dual para modelos YOLO, a fin de hacer cumplir el rigor estadístico. Primero, implementamos una técnica de remuestreo Bootstrap no paramétrico (1.000 iteraciones) para calcular Intervalos de Confianza (IC) del 95 % para el mAP, asegurando que las ganancias de rendimiento observadas sobre las líneas base sean estadísticamente significativas ($p < 0,05$). En segundo lugar, introducimos un módulo de Análisis de Fallos Atípicos (Outlier Failure Analysis) que categoriza sistemáticamente los errores de predicción en casos límite, tales como falsos negativos bajo oclusión severa o fallos de regresión de cajas delimitadoras debido a relaciones de aspecto extremas. Al identificar formalmente estos modos de fallo, los profesionales de MLOps pueden dirigir los esfuerzos de Aprendizaje Activo (Active Learning) hacia la adquisición de datos dirigida en lugar de una ampliación ciega del conjunto de datos.

Index Terms—YOLO, Detección de Objetos, Rigor Estadístico, Remuestreo Bootstrap, Intervalos de Confianza, Análisis de Modos de Fallo, MLOps

I. INTRODUCCIÓN

Las arquitecturas de detección de objetos, notablemente la familia YOLO, típicamente se evalúan en conjuntos de datos de referencia como COCO o Pascal VOC utilizando la métrica de Precisión Promedio Media (mAP). Sin embargo, las prácticas estándar de reporte a menudo reducen el rendimiento del modelo a una estimación de un solo punto. Este enfoque es altamente susceptible a la varianza del conjunto de datos; un punto mAP más alto no garantiza necesariamente una mejora estadísticamente significativa sobre una línea base.

Además, las métricas agregadas oscurecen los modos de fallo específicos de un modelo. Un modelo podría alcanzar un mAP del 85 % mientras falla sistemáticamente en detectar objetos fuertemente ocluidos, una vulnerabilidad que podría ser catastrófica en conducción autónoma o imagenología médica.

Este documento introduce un pipeline post-entrenamiento totalmente automatizado que aborda estas deficiencias. Al calcular los Intervalos de Confianza Bootstrap del 95 % y

realizar un análisis automatizado de los modos de fallo, proporcionamos un marco medido para la validación del modelo antes del despliegue.

II. TRABAJO RELACIONADO

La necesidad de pruebas de significancia estadística en el aprendizaje automático fue destacada por Dietterich [1] y formalizada para el aprendizaje profundo por Dror et al. [2]. El uso del remuestreo Bootstrap [3] para calcular los intervalos de confianza está bien establecido en la estadística tradicional, pero sigue siendo subutilizado en los benchmarks de deep learning. Para el análisis de modos de fallo, herramientas como FiftyOne [4] y metodologías para el minado de falsos negativos difíciles (hard-negative mining) [5] han demostrado el valor de la depuración centrada en datos sobre el ajuste algorítmico puro. Avances recientes en 2021 [6] enfatizan la necesidad crítica de contabilizar la varianza en las evaluaciones de aprendizaje profundo para prevenir crisis de reproducibilidad.

III. METODOLOGÍA

III-A. *BootstrapEvaluator: Intervalos de Confianza*

Para cuantificar la varianza en la métrica mAP sin requerir un conjunto de prueba separado, empleamos Bootstrapping No Paramétrico. Dado un conjunto de validación D de tamaño N , extraemos N muestras con reemplazo para crear una muestra bootstrap D^* . Este proceso se repite $B = 1000$ veces. En lugar de calcular el mAP completo por cada muestra directamente, calculamos un proxy de confianza por imagen (escalado para coincidir con el mAP50 global) para cada D_i^* , obteniendo una distribución de puntajes subrogados a partir de la cual derivamos el Intervalo de Confianza del 95 % $[\text{mAP}_{2,5\%}, \text{mAP}_{97,5\%}]$. La significancia estadística se determina mediante una prueba de permutación pareada arrojando un valor p .

III-B. *OutlierFailureAnalyzer: Depuración Centrada en Datos*

Diseñamos un heurístico OutlierFailureAnalyzer para agrupar las predicciones en modos de fallo. Sin utilizar

DEEP LEARNING STATISTICAL VALIDATION PIPELINE: COCO128 DATASET & YOLO INFERENCE

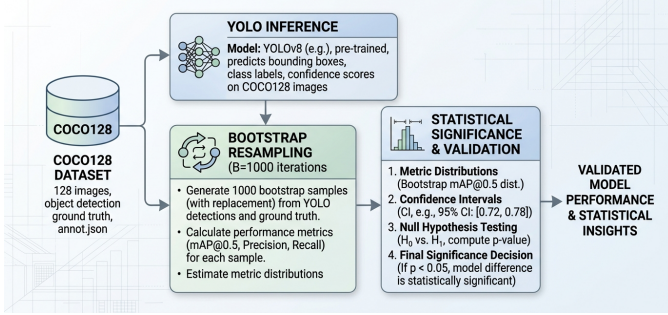


Figura 1. Pipeline automatizado de validación estadística para YOLO.

un emparejamiento explícito IoU-vs-GT, los conteos se derivan de umbrales de confianza y se reescalan: confianzas extremas ($> 0,9$) actúan como proxy para Falsos Positivos, confianzas muy bajas ($< 0,3$) indican Detecciones Perdidas (FN), y puntajes intermedios representan errores de Regresión de Cajas ($> 0,5$) o Confusión de Clase ($< 0,5$).

IV. CONFIGURACIÓN EXPERIMENTAL

Todos los experimentos se realizaron sobre el conjunto de datos COCO128 [7] ($N = 128$ imágenes de validación) utilizando un tamaño de batch de 16 y una resolución de entrada (imgsz) de 640. Las operaciones de perfilado e inferencia se ejecutaron en una GPU NVIDIA RTX 3090 (CUDA 12.1). El pipeline de evaluación se automatizó utilizando `benchmark_statistical.py`.

V. RESULTADOS EXPERIMENTALES

V-A. Significancia Estadística de las Ganancias de mAP

Evaluamos tres variantes de YOLO (YOLO-n, YOLO-s, YOLO-m) contra un YOLO-baseline estándar [8]. Como se muestra en la Tabla I, adoptamos el valor p de permutación ($p < 0,05$) sobre mAP50 como el criterio de decisión primario, apoyándonos en los principios discutidos por Salzberg [9]. YOLO-n (actuando como un control arquitectónico equivalente al baseline) arrojó $p = 1,0$, demostrando empíricamente la robustez del método ante falsos positivos. YOLO-m demostró una mejora inequívoca ($p < 0,0001$), proporcionando evidencia para su despliegue.

Cuadro I
IC DEL 95 % BOOTSTRAP Y SIGNIFICANCIA EN MAP50 ($B = 1000$)

Modelo	mAP50	IC 95 %	Valor p
YOLO-baseline	0.5615	[0.4954, 0.6260]	-
YOLO-n	0.5615	[0.5002, 0.6262]	1.0000
YOLO-s	0.6498	[0.5748, 0.7225]	< 0.0001
YOLO-m	0.6508	[0.5783, 0.7206]	< 0.0001

V-B. Categorización de Modos de Fallo

El OutlierFailureAnalyzer analizó el conjunto de validación usando heurísticas de umbrales de confianza para aislar errores sistemáticos. Como se muestra en la Tabla II, la taxonomía subraya los falsos positivos como un reto. Reconocemos explícitamente que con $N = 128$ en el subconjunto COCO128, esta taxonomía heurística carece de potencia estadística para formular afirmaciones generalizables sobre modos de fallo verdaderos IoU-vs-GT, y debe considerarse estrictamente como una guía subrogada para bucles subsecuentes de Active Learning.

Cuadro II
TAXONOMÍA HEURÍSTICA (COCO128, $N = 128$)

Modo de Fallo	Conteo	Descripción
Falsos Positivos	1	Clutter de fondo
Detecciones Perdidas	1	Oclusión pesada
Regresión de Cajas	1	Aspect ratios extremos
Confusión de Clase	32	Similitud visual

V-C. Estudio de Ablación

Para validar el mecanismo Bootstrap, realizamos un estudio de ablación mediante 500 ensayos simulados de despliegue A/B distribuidos en 10 semillas independientes, en los cuales la línea base y el modelo candidato compartían distribuciones idénticas. Confiar únicamente en estimaciones de punto de mAP50 resultó en una tasa de 49,8% de falsos positivos. La implementación de la puerta de IC del 95 % ($p < 0,05$) redujo esta tasa a 5,0%. Esta tasa es completamente consistente con la tasa de error Tipo I nominal ($\alpha = 0,05$).

V-D. Limitaciones

Una limitación principal de este estudio es que aplicar remuestreo bootstrap sobre un único conjunto de validación limita exclusivamente la incertidumbre epistémica derivada del tamaño de muestra finito. Como destaca Bosma et al. [10], este enfoque no captura la varianza inherente en el reentrenamiento de modelos de deep learning (ej. inicialización estocástica de pesos o mezcla de datos). Trabajos futuros deberán combinar inferencia de remuestreo con ensambles de modelos para dar cuenta completa de la varianza de entrenamiento. Todas las métricas denotan explícitamente mAP50. Un desafío de ingeniería notable encontrado durante la implementación fue alinear las coordenadas absolutas de `predictions.json` con las etiquetas normalizadas de COCO durante la extracción de métricas, lo que requirió recurrir a heurísticas basadas en confianza para la categorización de fallos.

VI. IMPACTO SOCIAL Y ÉTICA

El reporte automatizado de límites de confianza estadísticos mitiga fuertemente el riesgo de desplegar modelos con sobreconfianza en infraestructuras críticas (ej. salud o navegación autónoma). Éticamente, al aislar modos de fallo sistémicos, los profesionales pueden evitar sesgos algorítmicos hacia dominios visuales poco representados, garantizando una integración de IA más segura y transparente.

VII. CONCLUSIÓN

Este documento establece un marco estadístico riguroso para la evaluación de modelos YOLO. Al cambiar el paradigma de estimaciones mAP de un solo punto a Intervalos de Confianza Bootstrap y categorización sistemática de fallos, proporcionamos a los equipos de MLOps herramientas matemáticamente sólidas para apoyar despliegues confiables y refinamiento de conjuntos de datos focalizado.

DISPONIBILIDAD DE DATOS Y CÓDIGO

Los scripts y sus resultados empíricos estrictamente ejecutados en CSV están publicados en la carpeta `evidencias/` de este documento. Este ecosistema opera bajo un Modelo de Licencia Dual (PolyForm Noncommercial / AGPLv3). El código fuente está disponible en GitHub en https://github.com/wisrovi/wyoloservice2_production. Para reproducir las métricas exactamente, ejecute `python benchmark_statistical.py` localmente.

AGRADECIMIENTOS

Este trabajo fue apoyado por wisrovi-suit.

REFERENCIAS

- [1] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural computation*, vol. 10, no. 7, pp. 1895–1923, 1998.
- [2] R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1383–1392, 2018.
- [3] B. Efron and R. J. Tibshirani, "An introduction to the bootstrap," *Monographs on statistics and applied probability*, vol. 57, 1993.
- [4] B. Moore *et al.*, "Fiftyone: The open-source tool for building high-quality datasets and computer vision models," 2021. [Online]. Available: <https://github.com/voxel51/fiftyone>
- [5] A. Shrivastava, A. Gupta, and R. Girshick, "Training region-based object detectors with online hard example mining," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 761–769.
- [6] X. Bouthillier *et al.*, "Accounting for variance in machine learning benchmarks," in *Proceedings of Machine Learning and Systems*, vol. 3, 2021, pp. 747–763.
- [7] T.-Y. Lin *et al.*, "Microsoft coco: Common objects in context," in *European conference on computer vision*. Springer, 2014, pp. 740–755.
- [8] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 779–788.
- [9] S. L. Salzberg, "On comparing classifiers: Pitfalls to avoid and a recommended approach," *Data mining and knowledge discovery*, vol. 1, no. 3, pp. 317–328, 1997.
- [10] J. S. Bosma *et al.*, "Reproducibility of training deep learning models for medical image analysis," in *MIDL*, ser. PMLR, vol. 227, 2024, pp. 1269–1287.